

CIFAR-10 图像分类实验报告

李锐瞳

2024 年 10 月 31 日

摘要 (Abstract)

本实验的主要目标是在 CIFAR-10 数据集上训练一个卷积神经网络 (CNN) 模型，通过调整超参数和添加正则化项 (L2 正则化和 Dropout) 来提高模型性能。我们采用了一个基础的 LeNet 风格卷积神经网络，并观察了学习率和训练轮数对模型损失和准确率的影响。实验结果表明，在较小的学习率 (0.001) 和适当的训练轮数 (9-10) 的设置下，模型达到了最佳性能。此外，正则化方法有效减少了过拟合，进一步提升了测试集准确率。

引言 (Introduction)

CIFAR-10 是一个标准的图像分类数据集，包含 10 个类别的 32×32 彩色图像，广泛用于机器学习和计算机视觉算法的评估。该数据集包含 60,000 张图片，每个类别有 6,000 张，用于评估模型的分类能力。卷积神经网络 (CNN) 是一种常见的用于图像处理的模型结构，通过卷积层和池化层自动提取特征，在图像分类任务上表现出色。

本实验旨在通过在 CIFAR-10 数据集上训练卷积神经网络模型，探索超参数（如学习率和训练轮数）和正则化方法（L2 正则化和 Dropout）对模型性能的影响。实验中，我们采用了经典的 LeNet 风格卷积网络，重点分析了不同配置下模型在训练和测试集上的表现，并最终得到了较好的分类结果。

方法 (Methodology)

本实验通过以下方法完成图像分类任务：

1. 数据预处理

使用 PyTorch 中的 'torchvision' 库加载 CIFAR-10 数据集。图像数据在加载时经过归一化处理，将像素值归一化至 $[-1, 1]$ 区间，以便于网络处理。同时将数据划分为训

练集（50,000 张）和测试集（10,000 张），并使用 DataLoader 进行批量加载。

2. 模型设计

实验使用一个基础卷积神经网络，包含 2 个卷积层和 3 个全连接层。卷积层使用 ReLU 激活函数并添加最大池化层，全连接层同样使用 ReLU 激活函数。具体结构如下：

- Conv2d(3, 6, 5)：输入通道为 3（RGB 图像），输出通道为 6，卷积核大小为 5×5 。
- Conv2d(6, 16, 5)：输出通道增加到 16，卷积核大小为 5×5 。
- 三个全连接层：分别连接至 120、84 和 10 个神经元，最后的 10 个神经元对应 CIFAR-10 的 10 个类别。

3. 正则化方法

L2 正则化：通过在优化器中设置 ‘weight_decay’ 参数（值为 0.01）来实现。L2 正则化限制模型权重，防止过大的权重值，减少过拟合风险。

Dropout：在第一个和第二个全连接层之间插入 Dropout 层，丢弃概率设置为 0.5，以减少模型对特定特征的依赖。

4. 超参数设置

- **学习率**：分别尝试了 0.001 和 0.01，以观察不同学习率对模型收敛速度和准确率的影响。
- **训练轮数 (Epochs)**：设置为 5 到 10，观察训练轮数对模型性能的影响。

5. 训练与评估

记录每个 epoch 的损失值，并在测试集上评估模型性能，以测试准确率作为模型性能的最终评估指标。

实验 (Experiments)

实验设置 (Experimental Setup)

- **数据集**：CIFAR-10 数据集。
- **模型架构**：LeNet 风格的卷积神经网络，包含 2 个卷积层和 3 个全连接层。
- **正则化方法**：L2 正则化 (weight_decay=0.01) 和 Dropout (丢弃概率为 0.5)。
- **超参数**：学习率 0.001 和 0.01；训练轮数 5 到 10。

实验结果 (Main Results)

实验对不同学习率和训练轮数的组合进行了测试，观察了模型在训练集上的损失变化和在测试集上的准确率。

1. 学习率和训练轮数对模型性能的影响：

- 当学习率为 0.001 时，模型在训练过程中逐渐收敛。随着训练轮数的增加，测试集准确率逐步提升，最高达到了 58%。
- - 当学习率为 0.01 时，模型训练损失波动较大，难以稳定收敛，测试集准确率仅为 25%-30%。

2. 正则化方法的效果：

- L2 正则化有效抑制了模型的过拟合现象，使得模型在测试集上的表现得到了提升。
- Dropout 引入后，训练集上的准确率略有下降，但在测试集上表现更好，提高了泛化能力。

实验结果表格

学习率	训练轮数	最终训练损失	测试集准确率
0.001	5	1.3284	54%
0.01	5	1.9779	25%
0.001	6	1.2937	55%
0.01	6	1.9588	27%
0.001	7	1.2637	54%
0.01	7	1.9733	27%
0.001	8	1.2702	52%
0.01	8	1.9645	25%
0.001	9	1.2187	58%
0.01	9	1.9648	25%
0.001	10	1.2570	57%
0.01	10	1.9654	30%

表 1: 不同学习率和训练轮数下的实验结果




图 1: 在 epoch 数为 9, learning rate 为 0.01 时损失函数达到最低




图 2: 在不同 epoch 和学习率下的训练损失曲线：这些配置并非最优解

总结 (Conclusion)

实验结果表明，选择适当的学习率（如 0.001）和合理的训练轮数（9-10）可以帮助模型达到最佳的测试集准确率。此外，引入 L2 正则化和 Dropout 层可以有效减少模型的过拟合现象，提高模型的泛化能力。在本实验中，最高测试集准确率为 58%，出现在学习率为 0.001 且训练轮数为 9 的情况下。

在未来的研究中，可以尝试更深层次的卷积神经网络结构（如 ResNet 或 VGG），以及使用动态学习率调整策略，以进一步提升模型在 CIFAR-10 数据集上的性能。

讨论 (Discussion)

Q1: 训练集上的损失越小，说明模型的效果就越好吗？

A1: 在训练集上的损失越小，虽然表明模型在训练集上拟合得更好，但并不一定意味着模型的效果更好。训练集上损失很小但测试集上损失很大说明出现了严重的过拟合，我们需要关注的是模型的泛化能力，因此通过各种正则化方法（本文中为 $L2$ 正则化与 Dropout 正则化）来降低过拟合的风险。

Q2: 简述一下两种正则化方法的基本原理

- $L2$ 正则化通过在损失函数中加入模型权重参数的平方和作为惩罚项，从而抑制权重值变得过大。具体地说， $L2$ 正则化在损失函数 L 中添加一项 $\lambda \sum_i w_i^2$ ，其中 w_i 为模型的每个权重参数， λ 是控制正则化强度的超参数。因此，正则化后的损失函数可以表示为：

$$L' = L + \lambda \sum_i w_i^2$$

这种方式限制了权重的大小，从而抑制模型复杂度，防止过拟合。

- Dropout 是一种随机丢弃神经元的方法。在训练过程中，Dropout 会随机将一部分神经元的输出设为零，以防止模型对特定特征的过度依赖。丢弃率 p 控制了每层中丢弃的神经元比例，通常取值在 0.2 到 0.5 之间。在测试阶段，保留所有神经元，并将输出乘以补偿系数 $1 - p$ 以平衡训练和测试阶段的神经元数量。

Q3: 说明超参数（如 num_epoch、优化器的 lr）的变化，分析其对整个模型的影响

1. 训练轮数 (num_epoch)

训练轮数决定模型在整个训练集上训练的遍数。适当的训练轮数有助于模型达到良好的拟合效果，而过多的训练轮数可能导致过拟合。低轮数会导致欠拟合，模型在训练集和测试集上的表现均不理想；过多的训练轮数则可能使模型在训练集上表现较好，但在测试集上表现变差。

2. 学习率 (lr)

学习率是影响模型训练速度和收敛稳定性的重要超参数，决定了参数更新的步长大小。在本实验中，学习率设置过低（如 $lr=0.001$ ）时，模型参数更新缓慢，导致训练时间较长（训练时间可达 45 分钟）。尽管低学习率能够逐步接近最优解，但训练效率

明显下降。反之，学习率设置过高（如 $lr=0.01$ ）时，模型更新步长过大，容易在最优解附近来回跳动，损失值无法稳定收敛，表现为损失函数的震荡现象，无法收敛到最优解。适中的学习率则能帮助模型快速且稳定地收敛，在较短时间内达到理想的效果。在实际训练中，为了平衡训练时间与收敛效果，我们选择适当的学习率，以提高模型的训练效率和性能表现。

3. 超参数调整的影响

实验中，通过对不同的 `num_epoch` 和 `lr` 组合进行测试，我们发现模型在适中学习率和适当轮数下效果最佳。未来可使用学习率衰减等技术，进一步提升模型效果。

致谢 (Acknowledgements)

在本次实验的完成过程中，得到了老师与各位助教的悉心指导，使我在实验设计、模型训练以及报告撰写中得以顺利推进。此外，也感谢学校与阿里云提供了本次实验平台的资源支持。最后，感谢家人和朋友在此期间的支持，使我得以专注于实验并顺利完成。